

ENG 792 - Análise e visualização de dados com R (RStudio)

Jackson Rodrigues

2021-08-10

Contents

1	Apresentação	5
1.1	Hello World! - Sejam Bem Vindos!	5
2	Vamos ao que interesa	11
2.1	Conhecendo o R	11
2.2	Como R funciona	19

Chapter 1

Apresentação

1.1 Hello World! - Sejam Bem Vindos!



Este é o material para os alunos matriculados na disciplina **ENG 792 - Análise e Visualização de dados com R (RStudio)** oferecida pelo programa de pós-graduação em Meteorologia Aplicada da Universidade Federal de Viçosa (UFV).

Este curso foi criado e é ministrado por Jackson Rodrigues, professor da Universidade Federal Fluminense (UFF), mas também professor no programa de pós-graduação em Meteorologia Aplicada do Departamento de Engenharia Agrícola (DEA) da Universidade Federal de Viçosa (UFV).

Este curso foi construído pensando em minha saga para aprender algo utilizando o R em meu doutorado. Foi bastante dolorido, principalmente no começo quando eu nunca havia tido contato com a linguagem, na verdade, sabia quase nada em programação.

Desta forma, o público alvo é aquele que tem conhecimento

zero

sobre o assunto. Mas se você já sabe algo em qualquer nível, seja bem vindo também e podemos aprender juntos, você ensina o que você sabe e eu ensino o que eu sei.

A ideia principal deste curso é que o(a) aluno(a) que nada sabe de **R** seja exposto(a) a grande quantidade de conceitos e métodos para que o “gelo” seja quebrado e possa se virar sozinho ao término do curso. Desta forma, não é um curso de estatística, não é um curso de produção gráfica nem um curso produção de conteúdo (eg. modelagem), mas um curso de exposição, quase um “*how to*”. Vamos levantar demandas do dia a dia e tentar resolver os problemas comuns enfrentados pelo estudante na condução de suas análises.

Eventualmente algum especialista será convidado para dar uma aula, bater um papo, fazer uma apresentação e etc sobre um assunto específico.

O R é uma ferramenta espetacular para análise e produção de dados, bem como produção gráfica! Vamos começar devagar e ao poucos vocês vão se tornando autossuficientes. Muitas dúvidas surgem em fóruns, grupos e tanto outros canais de comunicação da comunidade de usuários de R.

Muitas vezes surgem perguntas como:

“Tem como fazer isso no R?”

A resposta imediada, devido à sua versatilidade, é:

“A pergunta não é “se tem jeito”, mas “como fazer”.

Vamos dar uma passeio por muitas coisas legais que o **R** pode fazer e que vão ajudar a tornar sua vida bem melhor. Com tempo ganho na otimização das suas tarefas por utilização do **R** sobrará tempo para você escrever um paper a mais na pós-graduação, dormir no final de semana sem culpa, tomar uma cerveja na sexta com a turma e ir ao culto domingo sem pedidos.

Vamos fazer tudo isso nos divertindo. É legal! Vocês verão. Por isso não se preocupem comigo (professor), será muito pior para mim por ter que corrigir trabalhos enquanto vocês produzem mais um paper, dormem, tomam um cerveja com a turma e/ou rezam como foi na véspera de natal de 2020 quando estava corrigindo trabalhos.

Let's ride to Metal Land!

Não se sintam pressionados ou intimidados, façam as perguntas que quiserem. Eu também não sei tudo, o R é uma ferramenta que está em constante desenvolvimento tornando impossível acompanhar cada novidade. Caso eu não saiba uma resposta não tenho problemas em dizer que não sei, mas vou me esforçar para buscar a resposta.

Por isso:

- Vamos aprender e tentar nos divertir;
- Pensei nesse curso como uma forma de lutar contra a “dor” que senti quando comecei a trabalhar no R sozinho;
- Então sou um usuário e não um programador;




Figure 1.1: Véspera de Natal 2020

- A verdade é que o R tem uma curva de aprendizado muito íngreme que uma vez vencido o primeiro obstáculo as coisas deslancham;
- Vamos trabalhar de maneira que esse curso atenda superficialmente suas demandas e que te habilitem a se virarem sozinhos;
- Então vamos seguir passo-a-passo para um aprendizado gradual com vários exemplos;
- Tudo que você aprender em determinando momento não será descartado, você deverá guardar aquele conhecimento para utilização em próximo trabalho ou tarefa;
- Ou ainda, este conhecimento inicial será utilizado para sedimentar o caminho para um próximo passo;
- Aplicar o máximo possível nosso conhecimento a problemas reais, do mundo real.

Para finalizar gostaria de deixar algumas coisas claras.

- Este curso conta com vasto material encontrado em artigos, livros, blogs especializados, grupos de discussões e etc. Desta forma, caso encontre por aí algo que ofertei em aula não precisa me chamar de picareta. Provavelmente foi tirado de lá mesmo.

- O curso funciona como um *How to*. Não teremos tempo de nos aprofundar nas teorias dos assuntos aqui apresentados (nem é a intenção), por isso, vou mostrar o “**que é**”, “**como usar**” e “**como fazer**”.
- Ao término de cada aula será mostrada uma bibliografia básica sobre o conteúdo. Como são conteúdos diversificados, acho melhor separar as bibliografias por aula.

1.1.1 Sobre

Este é um material de apoio compilado e criado para os alunos da disciplina **ENG 792 - Análise e visualização de dados com R (RStudio)**.

Importante mencionar que o conteúdo aqui apresentado é um compilado de vários anos de materiais estudados disponíveis *online* ou em livros e artigos especializados. Desta forma, caso identifique algum conteúdo apresentado aqui que não esteja devidamente referenciado fique à vontade para solicitar os devidos créditos aos autores originais. Não tenho a intenção de ter crédito que não é meu.

1.1.2 Utilização

Cada capítulo é referente ao conteúdo de mais ou menos uma semana de curso. Cada semana trata de um assunto diferente e complementar ao conteúdo da semana anterior. Desta forma, fique livre para ir e vir no conteúdo caso algo não esteja claro o suficiente.

- Teremos aulas gravadas e aulas síncronas através de alguma plataforma.
- Apenas os alunos matriculados na disciplina terão acesso ao conteúdo gravado.
- A distribuição e/ou compartilhamento do conteúdo gravado por qualquer meio é proibido.

1.1.3 Códigos e Dados

Todo o material necessário para acompanhar a disciplina será oferecido via github. Os códigos com alguma explicação neste material online (explicação completa nas aulas) e os dados onde forem possíveis de serem armazenados.

1.1.4 Cronograma de aulas

As aulas serão ofertadas por material gravado e presencial às quintas e sextas entre 14:00 e 15:30.

Semana	Conteúdo
1.1	Apresentação do Conteúdo e Instalação do R
1.2	Funcionamento do R, tipo e estrutura dos objetos
2.1	Manipulação de dados 1
2.2	Manipulação de dados 2, testes lógicos e simbolos, condicionais e interações
3.1	Pacotes e Funções
3.2	Entrando/Importando dados. definição de diretórios
4.1	Produção gráfica com Rbase
4.2	Produção gráfica com ggplot 2
5.1	Elementos de estatística básica 1 (Est. Descritiva, Med. Tend. Central, Medi. de variabilidade)
5.2	Elementos de estatística básica 2 (Dife. Entre médias, T-Student, Teste F, Testes de normalidade)
6.1	Elementos de estatística básica 3 (ANOVA, delineamento, comparação múltiplas, Regressão, Resíduos, Homocedasticidade, Normalidade dos resíduos, regressão múltipla, superfície de resposta)
7.1	Análise Multivariada (Análise de agrupamento, medidas de (dis)similaridade, métodos de conexão, número de clusters, produção de dendogramas, árvores de decisão)
7.2	Métodos de Ordenação (Ana. Componentes Principais, Análise Canônica, Análise de fatores, Análise de Mahalanobis)
8 - 15	Será preenchido em breve

1.1.5 Métodos de avaliação

- Faremos pelo menos 3 listas de exercícios distribuídas pelo semestre.
- O trabalho final será a confecção de um atrabalho autoral com o conteúdo do curso que poderá ser feito em grupo (isso será definido ainda em conversa com vocês). Este trabalho será apresentado na forma de seminário ao término do curso.

Chapter 2

Vamos ao que interessa

2.1 Conhecendo o R

2.1.1 O que é o R?

É uma linguagem de programação voltada para resolução de problemas estatísticos, tratamento e visualização de dados.

Para Peng [2020] essa resposta é simples, “*R é um dialeto do S*”.

De acordo com Perlin [2018] *O código base do R foi inicialmente criado no laboratório da Bell/ AT&T por John Chambers e seus colegas, com base na linguagem S. Esse código foi reaproveitado por dois acadêmicos, Ross Ihaka e Robert Gentleman, resultando na plataforma de programação que temos hoje. Para os curiosos, o nome R foi escolhido devido ao compartilhamento da primeira letra do nome de seus criadores.*



O R está em constante desenvolvimento por um grupo chamado R Team Core e conta com colaboração gratuita de centenas de milhares de usuários e desenvolvedores ao redor do mundo. Por isso, atualmente o R é utilizado por diversas áreas do conhecimento variando das ciências humanas até exatas, naquelas ciências que poderíamos imaginar pouco ou nada relacionadas. Por isso não se limite a procurar informações apenas no seu nicho, abra sua mente e busque aprender


de outras ciências também. Eu, particularmente, busco muita coisa na econometria. embora presente em todo tipo de livro sobre R, esta citação acima (Perlin [2018]) é de um livro de econometria. Veremos mais conteúdos desse material em breve.

R é um software livre de análise de dados (não só estatística) que funciona em diversos sistemas operacionais: GNU Linux, Microsoft Windows, Mac OS X e outros.

O aprendizado do R é difícil no início devido à necessidade de se adaptar à sua lógica de funcionamento, se acostumar com a estrutura dos seus documentos de ajuda e memorizar alguns comandos básicos.

```
eq = function(x){x*x}
plot(eq(1:1000), type="l", lwd=3, col="red", xaxt="n", yaxt="n", xlab="Tempo", ylab="Apre-
```

Curva de Aprendizado



É preciso bastante perseverança e motivação para aprender os comandos básicos, e disposição para ler as páginas de ajuda e os manuais. Entretanto, depois de um certo tempo, ele possibilita que se trabalhe com grande produtividade e, o que é mais importante, eficácia e independência.

Leia também sobre o mito da curva de aprendizado do R.

2.1.2 Instalação do R

O **R** é um software gratuito para análises estatísticas e além. Pode ser baixado de The R Project for Statistical Computing.

Clique em **download R**.



[Home]

Download

CRAN

R Project

About R

Logo

Contributors

What's New?

Reporting Bugs

Conferences

Search

Get Involved: Mailing Lists

Developer Pages

R Blog

The R Project for Statistical Computing

Getting Started

R is a free software environment for statistical computing and graphics. It compiles and runs on a wide variety of UNIX platforms, Windows and MacOs. To [download R](#), please choose your preferred CRAN mirror.

If you have questions about R like how to download and install the software, or what the license terms are, please read our answers to frequently asked questions before you send an email.

News

- [R version 4.1.1 \(Kick Things\) prerelease versions](#) will appear starting Saturday 2021-07-31. Final release is scheduled for Tuesday 2021-08-10.
- [R version 4.1.0 \(Camp Fontanexen\)](#) has been released on 2021-05-18.
- [R version 4.0.5 \(Shake and Throw\)](#) was released on 2021-03-31.
- Thanks to the organisers of useR! 2020 for a successful online conference. Recorded tutorials and talks from the conference are available on the [R Consortium YouTube channel](#).
- You can support the R Foundation with a renewable subscription as a supporting member

Escolha o “espelho”. Escolha o mais próximo de você.

CRAN Mirrors

The Comprehensive R Archive Network is available at the following URLs, please choose a location close to you. Some statistics on the status of the mirrors can be found here: main page , windows release , windows old release .	
If you want to host a new mirror at your institution, please have a look at the CRAN Mirror HOWTO .	
0-Cloud	Automatic redirection to servers worldwide, currently sponsored by RStudio
Algeria	https://cran.utphb.dz/
Argentina	https://mirror.fcslq.unlp.edu.ar/CRAN/
Australia	https://cran.csiro.au/ https://mirror.uair.net.au/pub/CRAN/ https://cran.ms.unimelb.edu.au/ https://cran.curta.edu.au/
Austria	https://cran.wu.ac.at/
Belgium	https://www.freestatistics.org/cran/ https://fb.be/mirror/CRAN/
Brazil	https://pde.kaeser.br/mirror/cran/ https://mrcr.kaeser.br/ https://crna.fcmmv.br/ https://vm.fmrp.usp.br/CRAN/ https://tricfer.caioi.ups.br/CRAN/
Bulgaria	https://fb.uni-sofia.bg/CRAN/
Canada	https://mirrors.cs.ubc.ca/mirror/CRAN/ https://mirror.ca.mirosoft.ca/ https://mirrors.cs.dal.ca/cran/

Escolha o seu sistema operacional. Caso você seja usuário de windows clique em **Download R for Windows** em seguida em **install R for the first time** e finalmente em **Download R 4.1.0 for Windows**. Veja que no momento que este tutorial foi feito a versão mais recente é a 4.1.0. No vídeo abaixo a versão é uma anterior, mas a lógica é a mesma.

The Comprehensive R Archive Network

[Download and Install R](#)

Precompiled binary distributions of the base system and contributed packages. **Windows and Mac** users most likely want one of these versions of R:

- [Download R for Linux \(Debian, Fedora/Redhat, Ubuntu\)](#)
- [Download R for macOS](#)
- [Download R for Windows](#)

R is part of many Linux distributions, you should check with your Linux package management system in addition to the link above.

[Source Code for all Platforms](#)

Windows and Mac users most likely want to download the precompiled binaries listed in the upper box, not the source code. The sources have to be compiled before you can use them. If you do not know what this means, you probably do not want to do it!

- The latest release (2021-05-18, Camp Pontanezen) [R-4.1.0.tar.gz](#), read [what's new](#) in the latest version.
- Sources of [R alpha and beta releases](#) (daily snapshots, created only in time periods before a planned release).
- Daily snapshots of current patched and development versions are [available here](#). Please read about [new features and bug fixes](#) before filing corresponding feature requests or bug reports.
- Source code of older versions of R is [available here](#).
- Contributed extension [packages](#)

[Questions About R](#)

- If you have questions about R like how to download and install the software, or what the license terms are, please read our [answers to frequently asked questions](#) before you send an email.

clique aqui para assistir ao vídeo de instalação do R e RStudio no windows

Eu não tenho um sistema operacional de cada para mostrar a instalação, por isso deixo este vídeo para instalação no linux e este para instalação no mac. Caso você não consiga instalar me procure.


2.1.3 Primeiro contato



Temos 1 arquivo .csv com mais de 50.000 linhas referentes a transações de venda de diamantes dividida em 3 colunas *clarity*, *carat* e *price*. Quanto mais claro mais caro, certo? Ou há sub ou super valorização? Vamos investigar se essa relação é verdadeira.


```
mydata<-read.csv("J:/ENG_792/ENG_792-AVDR/ENG.792-AVDR/Cap_1_P2-Mispiced-Diamonds.csv"

library("ggplot2")
ggplot(data=mydata, aes(x=carat, y=price))+
  geom_point()
```




Faz algum sentido. Mas temos pontos que não são estatisticamente significantes à direita, então vamos fazer uma limpeza, vamos mexer na transparência.

```
ggplot(data=mydata, aes(x=carat, y=price, colour=clarity))+
  geom_point()
```



Vamos nos livrar dos pontos não significativos, aqueles que são *carat* menores que 2.5.


```
ggplot(data=mydata,
       aes(x=carat, y=price, colour=clarity))+
  geom_point(alpha=0.1)
```



brown é a melhor claridade, vejam que temos mispricing onde as linhas se cruzam.

```
ggplot(data=mydata[mydata$carat<2.5,],
       aes(x=carat, y=price, colour=clarity))+
  geom_point(alpha=0.1) +
  geom_smooth()
```

```
## `geom_smooth()` using method = 'gam' and formula 'y ~ s(x, bs = "cs")'
```




Executando o código abaixo você produzirá uma Modelo Digital do Terreno em 3D em uma janela **pop up** do pacote rayshader.

```
library(rayrender)
library(rayshader)
library(magick)

#Here, I load a map with the raster package.
loadzip = tempfile()
download.file("https://tylermw.com/data/dem_01.tif.zip", loadzip)
localtif = raster::raster(unzip(loadzip, "dem_01.tif"))
unlink(loadzip)


#And convert it to a matrix:
elmat = raster_to_matrix(localtif)

#We use another one of rayshader's built-in textures:
elmat %>%
  sphere_shade(texture = "desert") %>%
  add_water(detect_water(elmat), color = "desert") %>%
  plot_3d(elmat, zscale = 10, fov = 0, theta = 60, zoom = 0.75, phi = 45, windowsize = c(1000, 800))
```



Agora vamos adicionar mais algumas informações como escala e Norte.

```
render_scalebar(limits=c(0, 5, 10),label_unit = "km",position = "W", y=50,scale_length  
render_compass(position = "E")  
Sys.sleep(0.2)  
render_highquality(samples=200, scale_text_size = 24,clear=TRUE)
```



2.2 Como R funciona

Diferentemente de outras linguagens, todos os comandos escritos são diretamente executados, desta forma o R não precisa de um compilador para executar os comandos como Fortran. Por isso, torna-se uma linguagem muito mais amigável e acessível para não programadores.

A linguagem é muito intuitiva (quase uma sintaxe lógica). Por exemplo uma regressão linear pode ser executada como `lm(x~y)` (`lm` vem de linear model). Como no exemplo do modelo linear acima, sempre que formos executar um comando temos que seguir da seguinte forma função(dados e demais ajustes ou parâmetros), ou seja chame a função e coloque o resto dentro de parênteses.

Como dito anteriormente em aula, tudo que é executado pelo R fica armazenado na memória ativa (RAM) do computador na forma de objetos que possuem um nome. Os objetos, que variam em tipos e estruturas, podem ser funções criadas pelo próprio usuário, dados criados ou importados de uma memória, expressões e etc. Antes de entrarmos em detalhes sobre funções ou expressões, vamos nos ater aos objetos enquanto tipo na sequência suas estruturas.

Dica de livro de cabeceira sobre R Mello and Peternelli [2013].

2.2.1 Tipos de objetos

Os objetos no R podem ser do tipo *lógico*, *inteiro*, *simples*, *dupla*, *complexo*, *função* ou *caractere*.

mode()	Armazenamento	Exemplo
logical	lógico	TRUE or FALSE
numeric	inteiro, simples ou dupla	Números 1, 3.14, 2e-308 etc
complex	complexo	3+2i
function	função	Soma<-function(...)
name	caractere	média

Tabela 1: Tipos de modos para objetos no R.

```
#logical
q1 <-T
mode(q1);typeof(q1)

## [1] "logical"

## [1] "logical"
q2 <- FALSE #pode ser a palavra toda mas em maiúsculas
mode(q2);typeof(q2)

## [1] "logical"

## [1] "logical"
#integer
x<-2L #L garante que 2 será integer
mode(x);typeof(x)

## [1] "numeric"

## [1] "integer"
#double
y<-2.5
mode(y);typeof(y)

## [1] "numeric"

## [1] "double"
#Complex
z<-3+2i
mode(z);typeof(z)

## [1] "complex"

## [1] "complex"
```

```
#function
Soma<-function(x,y){
  x+y
}
mode(Soma);typeof(Soma)

## [1] "function"
## [1] "closure"
#Character
a <-"h" #Para colocar uma letra em uma variável é preciso colocar entre ""
mode(a);typeof(a)

## [1] "character"
## [1] "character"
média<-"média"
mode(a);typeof(a)

## [1] "character"
## [1] "character"
```

Saber as diferenças entre os diversos objetos é importante para uma exploração mais adequada dos dados, utilização eficiente de funções ou operações lógicas, aritméticas, estatísticas e etc.

Veja que no caso acima em *integer* (*x <- 2L*) optamos por adicionar “L” após o número 2, pois o R por padrão decide onde e como aloca/aloja/armazena um operador. A informação será preferencialmente salva como *double* e isso faz sentido caso você queira mais adiante realizar operações com números decimais ou realizar operações que resultem em números decimais.

No entanto, caso queira saber que tipo de dado está manipulado você pode “perguntar” utilizando *is.* seguido da designação do tipo de dados quer testar (*integer*, *numeric*, *double* e etc) e teremos uma resposta lógica.

```
is.double(x)
```

```
## [1] FALSE
```

Caso você deseje que sua variável seja de um tipo específico, você pode transformá-la utilizando *as.* seguido da designação desejada (*integer*, *numeric*, *double* e etc).

```
x<-as.double(x)
is.double(x)
```

```
## [1] TRUE
```

Cada tipo de dado é associado com um teste e uma função de conversão conforme a tabela 2.

Tipo	Teste	Função de conversão
character	is.character	as.character
complex	is.complex	as.complex
double	is.double	as.double
expression	is.expression	as.expression
integer	is.integer	as.integer
list	is.list	as.list
logical	is.logical	as.logical
numeric	is.numeric	as.numeric
single	is.single	as.single
raw	is.raw	as.raw
Date	is.Date	as.Date

Tabela 2: Tipos de dados, teste e modos de conversão.

2.2.2 Estrutura do objetos

As informações armazenadas em objetos no R podem ser organizadas em diferentes estruturas.




Figura 1: Estrutura de dados no R. Fonte: techvidvan

Objeto	modes	Descrição
vector	numeric, character, complex ou logical	Com um ou mais elementos
factor	numeric ou character	Vetor que representa dados
matriz	numeric, character, complex ou logical	Um array de duas dimensões
array	numeric, character, complex ou logical	Pode conter um, duas ou mais arrays
data frame	numeric, character, complex ou logical	Um array de duas dimensões
list	numeric, character, complex, logical, function, expression, ...	Objeto que permite combinar tipos diferentes

Tabela 3: Características dos tipos de objetos.

2.2.2.1 Vetores (*Vectors*)

Vetores são os tipos de objetos mais comuns no R. Um vetor é composto de uma informação ou uma série de informações (*arrays*) unidimensionais que podem conter informações numéricas, caracteres ou dados lógicos.

Mesmo quando digitamos apenas um único elemento ele se torna um vetor de comprimento um (1).

Vetores com Apenas 1 elemento

```
esquerdo<-("direito") # O objeto "esquerdo" recebe a palavra "direito"
esquerdo #execute o arquivo e veja seu conteúdo
```

```
## [1] "direito"
direito=c("esquerdo") #Outra maneira de criar objeto
print(direito) #Outra forma de executar o conteúdo
```

```
## [1] "esquerdo"
b=(10) # O objeto "b" recebe o número 10
b

## [1] 10
(15.23)->c # O objeto "c" recebe o número 15.23
c
```

```
## [1] 15.23
```

Vetores com múltiplos elementos

```
d<-(0:10) # Criando uma sequência de 0 até 10
d
```

```
## [1] 0 1 2 3 4 5 6 7 8 9 10
e<-10.5:20.5 # criando uma sequência de 10.5 até 20.5
e
```

```
## [1] 10.5 11.5 12.5 13.5 14.5 15.5 16.5 17.5 18.5 19.5 20.5
```

```
f<-(10.6:20.3) # O último elemento é descartado por não encaixar na sequência
f
```

```
## [1] 10.6 11.6 12.6 13.6 14.6 15.6 16.6 17.6 18.6 19.6
```

Podemos utilizar também a função *seq* para gerar uma sequência de dados

```
seq(from = 1, to = 1, by = ((to - from)/(length.out - 1)), length.out = NULL,
along.with = NULL, ...)
```

```
g<-seq(0,10,0.5) # O objeto "g" recebe a sequência de 0 até 10 a cada 0.5
g
```

```
## [1] 0.0 0.5 1.0 1.5 2.0 2.5 3.0 3.5 4.0 4.5 5.0 5.5 6.0 6.5 7.0
## [16] 7.5 8.0 8.5 9.0 9.5 10.0
```

```
h<-seq(from=10,to=20,length.out=50) # O objeto "h" recebe a sequência de 0 até 10 que é do comprimento 50
h
```

```
## [1] 10.00000 10.20408 10.40816 10.61224 10.81633 11.02041 11.22449 11.42857
## [9] 11.63265 11.83673 12.04082 12.24490 12.44898 12.65306 12.85714 13.06122
## [17] 13.26531 13.46939 13.67347 13.87755 14.08163 14.28571 14.48980 14.69388
## [25] 14.89796 15.10204 15.30612 15.51020 15.71429 15.91837 16.12245 16.32653
## [33] 16.53061 16.73469 16.93878 17.14286 17.34694 17.55102 17.75510 17.95918
## [41] 18.16327 18.36735 18.57143 18.77551 18.97959 19.18367 19.38776 19.59184
## [49] 19.79592 20.00000
```

Experimente também a função `rep()`

```
rep(x, times = 1, length.out = NA, each = 1)
i<-rep(0,10) # O objeto "i" recebe 10 números 1
i

## [1] 0 0 0 0 0 0 0 0 0 0
j<-rep(c(1:3),10) # O objeto "j" recebe 10 vezes a sequência 1, 2 e 3
j

## [1] 1 2 3 1 2 3 1 2 3 1 2 3 1 2 3 1 2 3 1 2 3 1 2 3 1 2 3 1 2 3
```

Um Vetor só pode conter informações de um único tipo

```
k<-c(0,1,2,3,4, "A") # O objeto "k" é do tipo character por causa de "A"
typeof(k);mode(k)

## [1] "character"

## [1] "character"
l<-c(0,1,2,3,4) # O objeto "l" é do tipo numérico
typeof(l);mode(l)

## [1] "double"

## [1] "numeric"
```

2.2.2.2 Fatores (*Factors*)

Os fatores são vetores em que os elementos pertencem a uma ou mais categorias temáticas. As variáveis aleatórias podem ser divididas em contínuas e categóricas.

- As contínuas podem ser medidas nas escalas: relacional e intervalar.
- As categóricas nas escalas: nominal e ordinal.

No R, as variáveis categóricas medidas nas escalas nominal e ordinal são chamados fatores. A função `factor()` armazena os valores categóricos como um vetor de inteiros [1..k] e um vetor interno de *strings* referentes ao nomes. *Em outras palavras, um factor é um vetor objeto usado para especificar uma classificação discreta (agrupamento) dos componentes de outros vetores de mesmo tamanho.*

```

factor(x = character(), levels, labels = levels, exclude = NA, ordered =
is.ordered(x), nmax = NA)

ou

gl(n, k, length = n X k, labels = seq_len(n), ordered = FALSE)

m<-factor(c("H", "H", "H", "M", "M")) # O objeto "k" recebe 3 H's e 2 M's
m

## [1] H H H M M
## Levels: H M
as.integer(m)

## [1] 1 1 1 2 2
n<-gl(n=2,k=3,labels=c("M", "F"))
n

## [1] M M M F F F
## Levels: M F

```

Podemos verificar os níveis de um fator usando o comando *levels()*.

```

levels(m)

## [1] "H" "M"
levels(n)

## [1] "M" "F"

```

2.2.2.3 Matriz (*Matrix*)

É o tipo de dado mais comum que encontramos do dia a dia. A maioria dos dados que analisamos estão organizados em matrizes que são dados combinados em 2 dimensões (linhas e colunas). Existem várias maneiras de criar uma matriz como utilizando o comando *matrix()*.

```
matrix(data = NA, nrow = 1, ncol = 1, byrow = FALSE, dimnames = NULL)
```

Assim como os vetores, as matrizes só aceitam dados do mesmo tipo.

```

o<-1:10 # cria um vetor de 1 a 10
o_matriz1<-matrix(o,ncol=5)# Organiza o vetor 0 e 5 colunas
o_matriz1

##      [,1] [,2] [,3] [,4] [,5]
## [1,]     1     3     5     7     9
## [2,]     2     4     6     8    10
o_matriz2<-matrix(o,nrow=5)# Organiza o vetor 0 e 5 linhas
o_matriz2

```

```
##      [,1] [,2]
## [1,]    1    6
## [2,]    2    7
## [3,]    3    8
## [4,]    4    9
## [5,]    5   10
```

Podemos utilizar também o argumento *byrow*=, que, diferente do exemplo acima, preenchem as tabelas por linhas.

```
p<-1:10 # cria um vetor de 1 a 10
p_matriz1<-matrix(o,nrow=5,byrow=T) # Organiza o vetor O e 5 colunas
p_matriz1; o_matriz2 # compare os 2 modos
```

```
##      [,1] [,2]
## [1,]    1    2
## [2,]    3    4
## [3,]    5    6
## [4,]    7    8
## [5,]    9   10

##      [,1] [,2]
## [1,]    1    6
## [2,]    2    7
## [3,]    3    8
## [4,]    4    9
## [5,]    5   10
```

As dimensões de uma matriz pode ser acessado através do comando *dim()*:

```
dim(o_matriz1);dim(o_matriz2) # Leia o o resultado como linha e coluna
```

```
## [1] 2 5
## [1] 5 2
```

Também é interessante usar o comando *summary()*.

```
summary(o_matriz1);summary(o_matriz2) # Mostra informações por coluna
```

```
##          V1            V2            V3            V4            V5
##  Min.   :1.00   Min.   :3.00   Min.   :5.00   Min.   :7.00   Min.   : 9.00
##  1st Qu.:1.25   1st Qu.:3.25   1st Qu.:5.25   1st Qu.:7.25   1st Qu.: 9.25
##  Median :1.50   Median :3.50   Median :5.50   Median :7.50   Median : 9.50
##  Mean   :1.50   Mean   :3.50   Mean   :5.50   Mean   :7.50   Mean   : 9.50
##  3rd Qu.:1.75   3rd Qu.:3.75   3rd Qu.:5.75   3rd Qu.:7.75   3rd Qu.: 9.75
##  Max.   :2.00   Max.   :4.00   Max.   :6.00   Max.   :8.00   Max.   :10.00

##          V1            V2
##  Min.   :1   Min.   : 6
##  1st Qu.:2   1st Qu.: 7
```

```
## Median :3   Median : 8
## Mean    :3   Mean    : 8
## 3rd Qu.:4   3rd Qu.: 9
## Max.    :5   Max.    :10
```

Outras formas de construir matrizes é juntando objetos existentes através dos comandos *cbind()* e *rbind()* que contacatenam objetos por colunas e linhas, respectivamente.

Vamos juntar as matrizes já criadas.

```
o_matriz3<-rbind(o_matriz1,o_matriz1) # concatena por linhas (r)
o_matriz3
```

```
##      [,1] [,2] [,3] [,4] [,5]
## [1,]    1    3    5    7    9
## [2,]    2    4    6    8   10
## [3,]    1    3    5    7    9
## [4,]    2    4    6    8   10
```

```
o_matriz4<-rbind(o_matriz2,o_matriz2) # concatena por colunas (c)
o_matriz4
```

```
##      [,1] [,2]
## [1,]    1    6
## [2,]    2    7
## [3,]    3    8
## [4,]    4    9
## [5,]    5   10
## [6,]    1    6
## [7,]    2    7
## [8,]    3    8
## [9,]    4    9
## [10,]   5   10
```

2.2.2.4 Array

O array é um conjunto de matrizes ou vetores que podem ter qualquer número de dimensões. Estas dimensões podem receber nomes. Podemos criar *arrays* atribuindo dimensões a um vetor com o comando *dim()* ou usando *array()*.

```
array(data = NA, dim = length(data), dimnames = NULL)
q_array<-1:12 # cria um vetor
dim(q_array)<-c(2,3,2) # atribuindo 3 dimensões a q_array
q_array

## , , 1
##
##      [,1] [,2] [,3]
```

```

## [1,]    1    3    5
## [2,]    2    4    6
##
## , , 2
##
## [,1] [,2] [,3]
## [1,]    7    9   11
## [2,]    8   10   12
r_array<-array(1:12,c(2,3,2)) # cria um array de 3 dimensões
r_array

```

```

## , , 1
##
## [,1] [,2] [,3]
## [1,]    1    3    5
## [2,]    2    4    6
##
## , , 2
##
## [,1] [,2] [,3]
## [1,]    7    9   11
## [2,]    8   10   12

```

2.2.2.5 Data Frame

Tão comum quanto a matriz, o data frame também um modo bidimensional de organização dos dados (linhas e colunas) que, diferentemente da matriz, permite objetos de tipos diferentes (character, numeric, logical e etc)sejam armazenados. Normalmente, nos data frames temos nas linhas as observações e nas colunas temos as variáveis. No entanto, é importante que cada coluna tenha o mesmo tamanho.

```
data.frame(..., row.names = NULL, check.rows = FALSE,check.names = TRUE,
fix.empty.names = TRUE,stringsAsFactors = default.stringsAsFactors())
```

Nome	Matrícula	Curso	Nivel.de.R	Nível.Pós
Alberto Domingos Macamo	0	Meteorologia Aplicada	NA	Mestrado
Ana Luiza Melo Rodrigues	98075	Engenharia Agrícola	0	Doutorado
Arieta Carla Gualandi Leal	88695	Nutrição	0	Doutorado
Caio Henrique Patrício Pagani	104129	Engenharia Agrícola	2	Doutorado
Carla Larissa Fonseca da Silva	104731	Engenharia Agrícola	3	Mestrado
Conrado Trigo de Moraes	104589	Zootecnia	1	Doutorado
Diego Bispo dos Santos Farias	0	Engenharia Agrícola	NA	Doutorado
Eloy Junior Rezende	104599	Zootecnia	0	Mestrado
Fernanda Gonçalves Borges	104162	Engenharia Agrícola	2	Mestrado
Flávio Dayrell Gontijo	101417	Botânica	4	Mestrado
Francilene Maria Azevedo	74843	Ciência da Nutrição	1	Doutorado
Lorena Moreira Lara	74038	Fitotecnia (melhoramento)	5	Doutorado
Luana Caldeira Fonseca Coutinho	81919	Biologia	1	Mestrado
Marconi Martins Cunha	70859	Engenharia Civil	3	Doutorado
Mathias Viana Vicari	0	Não informado	NA	Não informado
Mayara Oliveira Rocha	104557	Engenharia Agrícola	1	Doutorado
Michel Henriques de Souza	74102	Genética e Melhoramento	5	Doutorado
Moana Teixeira Rothe-Neves	104660	Ecologia	5	Mestrado
Pedro Dell'Isola Brauer	0	Meteorologia Aplicada	NA	Mestrado
Rafael Luís Silva Dias	0	Engenharia Agrícola	5	Doutorado
Samuli Laurindo Pereira	104525	Biologia	5	Mestrado
Sherellyn Daphnee Alves Moretti	100302	Ciência Florestal	1	Mestrado
Thales Maurino de Aquino Silva	91704	Engenharia Agrícola	0	Doutorado
Talitha Silva Meneguelli	0	Nutrição	NA	Doutorado
Vinícius Rodrigues dos Santos Petersen	86022	Meteorologia Aplicada	1	Mestrado
Victorina Bispo Aires	104275	Botânica	1	Mestrado
Welson Junior Silva	104283	Botânica	1	Mestrado
Rafael Bolina da Silva	104597	Zootecnia	4	Doutorado
Mathias Viana Vicari	0	Meteorologia Aplicada	NA	Doutorado
Jéssica Bevenuto Mattar	91502	Nutrição	1	Doutorado
Otávio Ferreira Santos	75179	Engenharia Agrícola	3	Mestrado
Joslanny Higino Vieira	98358	Engenharia Agrícola	5	Doutorado

Tabela 3: Data frame do alunos de ENG 792 III

```

Nome<-c("A", "B", "C")
Idade<-c(25, 32, 28)
Sexo<-c("M", "M", "F")
Nome;Idade;Sexo

```

```

## [1] "A" "B" "C"
## [1] 25 32 28
## [1] "M" "M" "F"

```

```
Ficha<-data.frame(Nome,Idade,Sexo)

attributes(Ficha) # exibe os atributos do data frame

## $names
## [1] "Nome"   "Idade"  "Sexo"
##
## $class
## [1] "data.frame"
##
## $row.names
## [1] 1 2 3



| Nome | Idade | Sexo |
|------|-------|------|
| A    | 25    | M    |
| B    | 32    | M    |
| C    | 28    | F    |


```

Tabela 4: Tabela com dados fictícios.

2.2.2.6 Lista (*list*)

List permite combinar diferentes estruturas de dados em um mesmo objeto, ou seja, *vetores*, *matrizes*, *arrays*, *data.frames* e até outras listas. As listas são construídas utilizando o comando *list()*

Os componentes da lista são criados da mesma maneira como para *data.frame*.
list(...)

```
Nome<-c("A")
Idade<-c(25)
Sexo<-c("M")
Notas<-c(55,42,50,35)
Nome;Idade;Sexo;Notas

## [1] "A"
## [1] 25
## [1] "M"
## [1] 55 42 50 35
Desempenho<-list(nome="A", idade=25, Sexo="M", Notas=c(55,42,50,35))
Desempenho

## $nome
## [1] "A"
##
## $idade
```

```
## [1] 25
##
## $Sexo
## [1] "M"
##
## $Notas
## [1] 55 42 50 35
is.list(Desempenho)
```

```
## [1] TRUE
```

Existem também alguns comandos/funções que mostram resultados como listas.

```
s<-c(1:30)
t<-c(30:59)

teste.t<-t.test(s,t, var.equal = T) # calcula o test t para 2 amostras de variâncias iguais
teste.t
```

```
##
## Two Sample t-test
##
## data: s and t
## t = -12.758, df = 58, p-value < 2.2e-16
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -33.54996 -24.45004
## sample estimates:
## mean of x mean of y
##      15.5      44.5
is.list(teste.t);mode(teste.t)
```

```
## [1] TRUE
```

```
## [1] "list"
```

Para finalizar por hoje preste atenção no seu *Global Environment*. Veja que há uma grande quantidade de objeto lá. Agora execute o comando abaixo:

```
rm(list=ls())
```

Voilà! Sumiu tudo.

Bibliography

M.P. Mello and L. A. Peternelly. *Conhecendo o R: Uma visão mais que estatística*. Editora UFV, first edition, 2013. ISBN 9788572694957.

R. D. Peng. *R Programming for Data Science*. bookdown, 2020. URL <https://bookdown.org/rdpeng/rprogdatascience/>.

M.S. Perlin. *Processamento e Análise de Dados Financeiros e Econômicos com o R*. Clóvis Nicacio, 2018. ISBN 9788592243562. URL <https://books.google.com.br/books?id=uxyluAEACAAJ>.